Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Pós-graduação em IA Generativa e Aplicações com LLMs
Disciplina: Machine Learning · Prof. Maurício Rodrigues da Silva

Propensão a Depósito a Prazo em Campanhas de Telemarketing Bancário

Trabalho Final: aplicação prática de Machine Learning com interface gráfica
Classificação com XGBoost, API FastAPI e interface web

Aluno: Rafael Brasil (trabalho individual)

Data: novembro de 2026

Dataset: Bank Marketing, UCI Machine Learning Repository

Repositório: github.com/rafaelmayerbrasil/trabalho-final-ml-bank-marketing

1. Introdução

Contexto

Bancos usam campanhas de telemarketing para oferecer produtos como o **depósito a prazo** (aplicação com prazo e rendimento definidos, equivalente a um CDB). Cada ligação ocupa o tempo de um atendente, e a grande maioria dos clientes recusa a oferta: na base estudada, apenas **11,7%** dos contatos terminaram em contratação. Ligar para todos os clientes da lista é caro e pouco eficiente.

Justificativa

Se fosse possível estimar, **antes da ligação**, quais clientes têm maior chance de aceitar, a equipe comercial poderia ordenar a fila de ligações pelos mais promissores: mais vendas com o mesmo esforço, ou o mesmo resultado com menos ligações. É um problema clássico de **classificação binária** (contrata / não contrata) com classes desbalanceadas, e permite exercitar todo o ciclo de um projeto de ciência de dados: análise exploratória, pré-processamento, comparação de modelos, escolha de métricas conforme o custo dos erros e disponibilização do modelo.

Objetivo

Construir um modelo que estime a probabilidade de um cliente contratar o depósito a prazo usando apenas informações disponíveis antes do contato, e disponibilizá-lo em uma interface web em que o usuário preenche os dados do cliente e recebe a probabilidade e uma recomendação de prioridade.

> **Os dois tipos de erro. Falso negativo**: o modelo descarta um cliente que contrataria (venda perdida, erro mais caro). **Falso positivo**: o modelo recomenda ligar para quem vai recusar (uma ligação desperdiçada, erro barato). Por isso o Recall importa, mas sem abrir mão da Precisão: ligar para todos tem Recall de 100% e não ajuda em nada.

2. Dataset

Fonte: *Bank Marketing*, de Moro, Cortez e Rita (2014), disponível no UCI Machine Learning Repository (`archive.ics.uci.edu/dataset/222/bank+marketing`, DOI 10.24432/C5K306). Foi usado o arquivo `bank-full.csv`, separado por ponto e vírgula, com dados reais de campanhas de um banco português entre maio de 2008 e novembro de 2010.

45.211	17	11,7%	0
contatos (linhas)	colunas (16 + alvo)	contrataram (classe positiva)	nulos e duplicatas

Coluna	Tipo	Descrição
`age`	numérica	Idade (anos)
`job`	categórica	Profissão (12 categorias)
`marital`	categórica	Estado civil
`education`	categórica	Escolaridade
`default`	binária	Tem crédito em atraso?
`balance`	numérica	Saldo médio anual (€)
`housing`	binária	Tem financiamento imobiliário?
`loan`	binária	Tem empréstimo pessoal?
`contact`	categórica	Meio de contato
`day`	numérica	Dia do mês do último contato
`month`	categórica	Mês do último contato
`duration`	numérica	**Duração da ligação (s). Removida: só é conhecida depois do contato**
`campaign`	numérica	Nº de contatos nesta campanha
`pdays`	numérica	Dias desde o contato anterior (−1 = nunca)
`previous`	numérica	Nº de contatos antes desta campanha
`poutcome`	categórica	Resultado da campanha anterior
`y`	alvo	**Contratou o depósito a prazo? (yes/no)**

Amostra dos dados (6 linhas sorteadas)

age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
36	blue-collar	married	secondary	no	349	yes	no	cellular	20	apr	365	1	-1	0	unknown	no
33	unemployed	single	secondary	no	177	no	no	unknown	8	may	75	4	-1	0	unknown	no
79	retired	divorced	secondary	no	631	no	no	telephone	9	aug	440	5	182	3	failure	no
26	admin.	single	secondary	yes	-42	no	yes	cellular	30	jul	305	3	-1	0	unknown	no
30	services	single	secondary	yes	0	no	yes	unknown	2	jul	95	3	-1	0	unknown	no
44	blue-collar	married	primary	no	2470	no	no	telephone	21	jul	19	1	-1	0	unknown	no

A base não tem valores nulos nem linhas duplicadas, mas usa o texto `unknown` como valor faltante disfarçado: 82% em `poutcome` (quase sempre cliente nunca contatado), 29% em `contact`, 4% em `education` e menos de 1% em `job`. O código `pdays = -1` significa "nunca contatado".

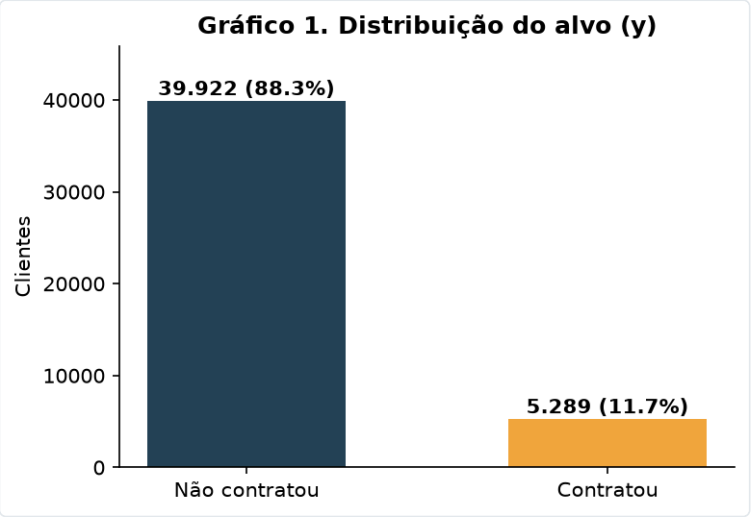


Figura 1. Distribuição do alvo: só 11,7% dos clientes contrataram (base desbalanceada).

3. Metodologia

3.1 Análise exploratória

Foram produzidos seis gráficos (distribuição do alvo, distribuições das variáveis numéricas por classe, correlação de Spearman, sazonalidade por mês, taxa de adesão por perfil e histórico, e duração da ligação por classe), cada um com interpretação escrita no notebook. As figuras mais relevantes aparecem na seção de Resultados.

3.2 Pré-processamento

Etapa	Decisão	Justificativa
Vazamento de dados	Remover `duration`	Só existe depois da ligação; mantê-la daria métricas infladas e um modelo inútil na prática
Valores `unknown`	Mantidos como categoria	Carregam informação: `contact = unknown` tem adesão de 4%
Nulos (NaN)	`SimpleImputer` (mediana/moda)	A base não tem NaN, mas o imputador protege a API contra campos ausentes
Encoding	`OneHotEncoder` (9 categóricas)	Variáveis nominais; `handle_unknown='ignore'` evita falhas com categorias novas
Normalização	`StandardScaler` (6 numéricas)	Necessária para a Regressão Logística
Split	80/20 estratificado, `random_state=42`	Treino 36.168 / teste 9.043, ambos com 11,7% de positivos

Todas as transformações ficam dentro de um `Pipeline` com `ColumnTransformer`, de modo que o imputador, o scaler e o encoder aprendem apenas com os dados de treino de cada dobra da validação cruzada, sem vazamento. Resultado: 15 variáveis de entrada viram 50 colunas após o encoding.

3.3 Modelos testados

Modelo	Papel
`DummyClassifier` (estratificado)	Baseline: "chute" na proporção das classes
Regressão Logística (`class_weight='balanced'`)	Modelo linear, interpretável
Random Forest (300 árvores, `class_weight='balanced_subsample'`)	Ensemble por bagging; capta não linearidades
XGBoost (`scale_pos_weight` ≈ 7,5)	Gradient boosting; referência em dados tabulares

Os modelos foram comparados por **validação cruzada estratificada com 5 dobras**, usando só o treino. O melhor foi refinado com **Grid Search CV** (profundidade, taxa de aprendizado e número de árvores; 8 combinações). O conjunto de teste foi usado **uma única vez**, na avaliação final.

3.4 Métricas

Como 88% dos clientes não contratam, a acurácia engana: um modelo que sempre responde "não" acerta 88% e não serve para nada. A comparação entre modelos usa o **ROC-AUC** (capacidade de ordenar clientes, independente do limiar) e o **PR-AUC** (mais sensível à classe rara). Também são reportados Acurácia, Precisão, Recall, F1, matriz de confusão e curva ROC.

3.5 Calibração e limiar de decisão

O peso dado à classe rara (`scale_pos_weight`) ajuda o XGBoost a **ordenar** os clientes, mas infla o número que ele devolve: em média o score bruto era 0,38, contra uma taxa real de 0,117. Como a interface mostra esse número como "chance de contratar", ele foi **calibrado** com o método de **Platt** (uma Regressão Logística sobre o score),

ajustado nas previsões *out-of-fold* do treino (`cross_val_predict`). A calibração não muda a ordem dos clientes nem o ROC-AUC, só o significado do número.

Como perder uma venda (FN) custa mais do que uma ligação à toa (FP), o limiar foi escolhido maximizando o **F2**, média de Precisão e Recall que dá **peso dobrado ao Recall**, também nas previsões *out-of-fold*, sem tocar no teste. O valor escolhido foi **0,11**, praticamente a taxa média de adesão. A regra para a equipe fica simples: **ligar para quem tem chance acima da média**.

4. Resultados

4.1 Análise exploratória: principais achados

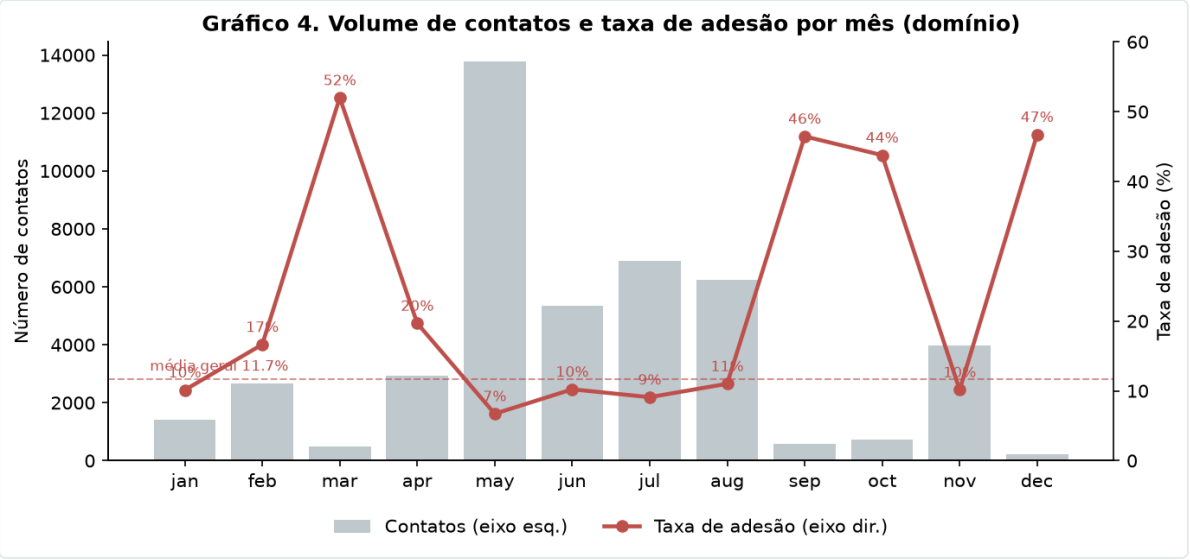


Figura 2. Volume de contatos e taxa de adesão por mês: maio concentra 30% das ligações e tem a pior taxa (7%); março, setembro, outubro e dezembro passam de 44%.

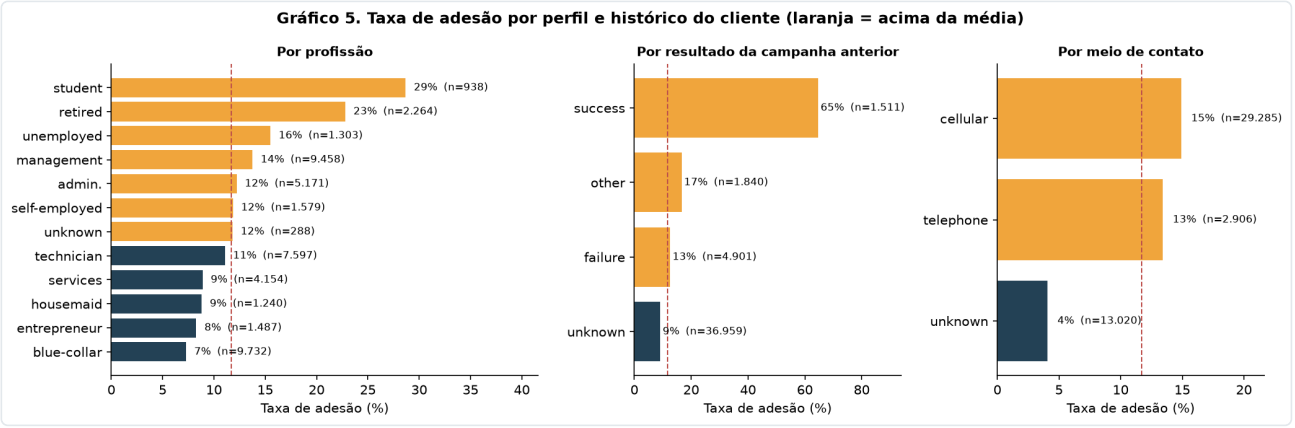


Figura 3. Taxa de adesão por profissão, resultado da campanha anterior e meio de contato. Quem aceitou na campanha anterior aceita de novo em 65% dos casos.

Outros achados: quem contrata se concentra nos extremos de idade (estudantes e aposentados); a chance cai à medida que o mesmo cliente recebe mais ligações; e a duração da ligação é muito maior entre quem contrata (mediana de 426 s contra 164 s), o que confirma que ela é **consequência** da venda e precisa ser excluída.

4.2 Comparação dos modelos (validação cruzada, 5 dobras, limiar 0,5)

Modelo	ROC-AUC (± desvio)	PR-AUC	F1	Recall	Precisão	Acurácia
Dummy (baseline)	0,499 ± 0,003	0,117	0,115	0,114	0,115	0,794
Regressão Logística	0,764 ± 0,003	0,399	0,373	0,622	0,266	0,755
Random Forest	0,793 ± 0,004	0,441	0,472	0,515	0,436	0,865
XGBoost	**0,796 ± 0,003**	**0,448**	**0,450**	**0,611**	**0,356**	**0,825**

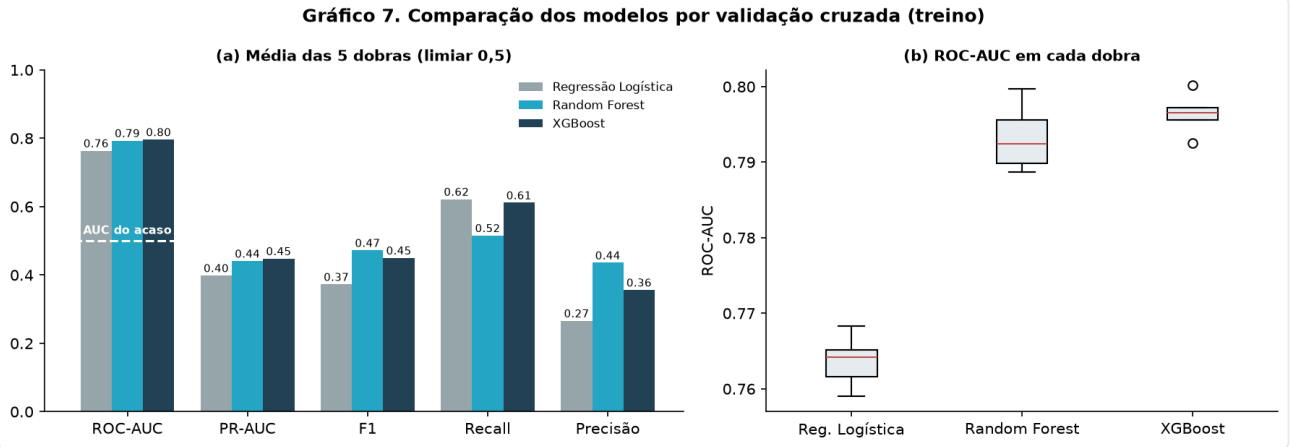


Figura 4. Métricas médias por modelo e estabilidade do ROC-AUC entre as dobras.

Todos os modelos superam o baseline com folga. Random Forest e XGBoost empatam tecnicamente e superam a Regressão Logística por captarem relações não lineares e interações. O **XGBoost** foi escolhido pela melhor ROC-AUC e PR-AUC médias e pelo arquivo leve para servir na API. O Grid Search escolheu `max_depth=3`, `learning_rate=0.1` e `n_estimators=300` (ROC-AUC de validação cruzada 0,7996), um ganho marginal sobre a configuração inicial.

4.3 Calibração e escolha do limiar

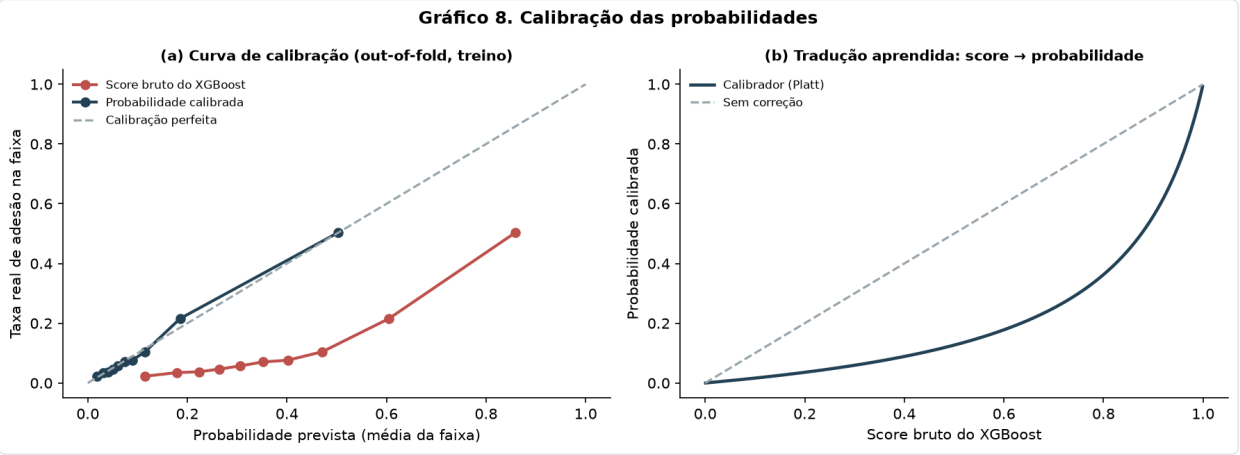


Figura 5. Curva de calibração antes e depois da correção de Platt (previsões out-of-fold no treino): o score bruto ficava muito acima da taxa real; o calibrado fica sobre a diagonal.

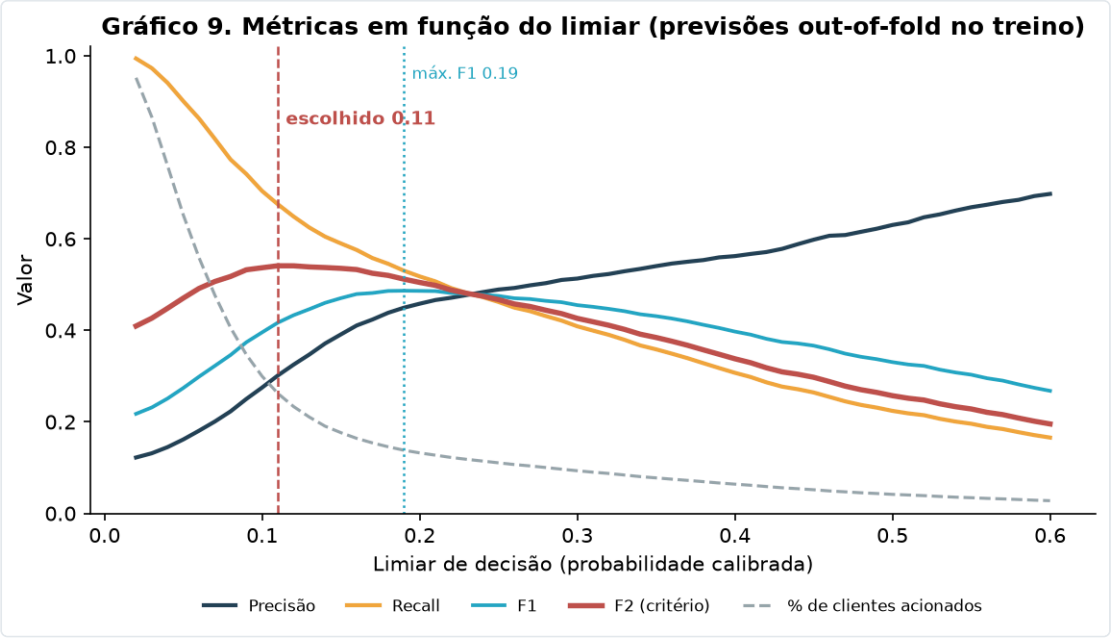


Figura 6. Precisão, Recall, F1 e F2 em função do limiar (probabilidades calibradas, out-of-fold no treino). Limiar escolhido pelo máximo F2: 0,11; o máximo do F1 ficaria em 0,19.

4.4 Avaliação final no conjunto de teste (9.043 clientes nunca vistos)

Regra	Acurácia	Precisão	Recall	F1	F2	ROC-AUC	% acionados
Escolhido: máx. F2 (0,11)	**0,776**	**0,301**	**0,691**	**0,419**	**0,548**	**0,804**	**27%**
Comparação: máx. F1 (0,19)	0,873	0,462	0,548	0,501	0,528	0,804	14%
Referência: sempre "não"	0,883	0,000	0,000	0,000	0,000	0,500	0%

O modelo encontra **69%** dos clientes que de fato contrataram e, das ligações que recomenda, **30%** viram venda, 2,6 vezes a taxa de 11,7% de uma campanha sem modelo. Em relação ao limiar do F1, deixa escapar 327 interessados em vez de 478. **A acurácia do modelo (0,776) é menor que a do modelo que sempre diz "não" (0,883)**, que tem Recall zero e não serve para nada. O modelo aceita, de propósito, ligações a mais para perder menos vendas, e é por isso que a acurácia não foi usada como critério. As probabilidades continuam calibradas no teste: por exemplo, clientes com previsão entre 40% e 60% contrataram 51% das vezes (Brier score 0,081).

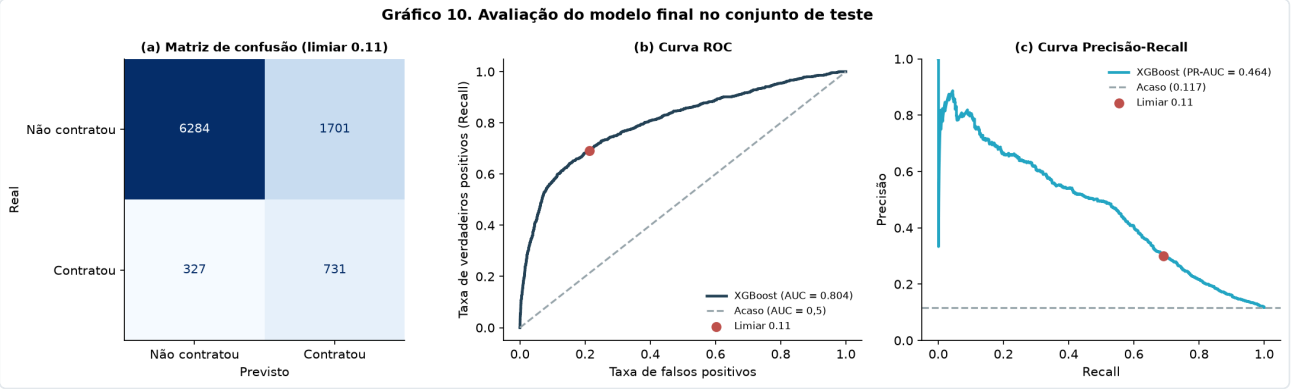


Figura 7. Matriz de confusão (VN=6.284, FP=1.701, FN=327, VP=731), curva ROC e curva Precisão-Recall no teste.

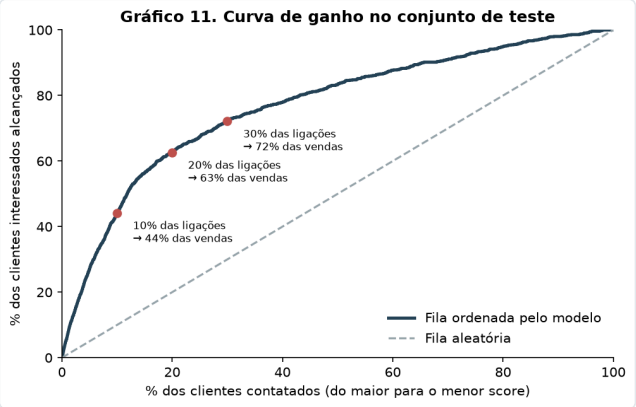


Figura 8. Curva de ganho: ligando para os 20% de maior probabilidade, o banco alcança 63% dos interessados.

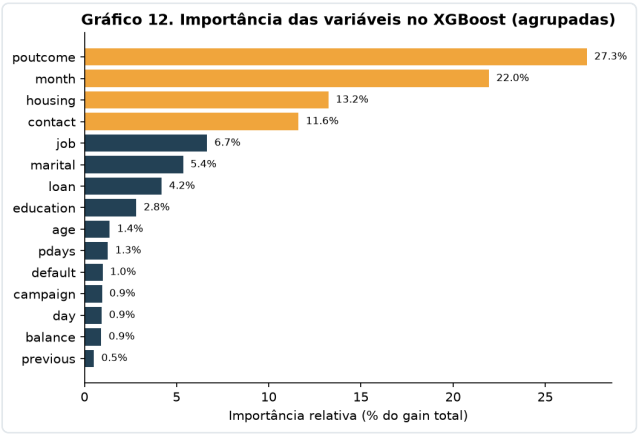


Figura 9. Importância das variáveis no XGBoost (gain agrupado por variável original).

4.5 Teste de robustez: treinar no passado, prever o futuro

O arquivo da UCI está em ordem cronológica. Treinando a mesma configuração nos 80% mais antigos e testando nos 20% mais recentes, o ROC-AUC cai de 0,80 para **0,66**. A taxa de adesão sobe de 3% no primeiro quinto do arquivo para 32% no último (*data drift*), e variáveis como `contact = unknown` marcam períodos, não clientes. O desempenho de 0,80 vale para o mesmo período; para uso real, o modelo precisaria ser retreinado e recalibrado com frequência.

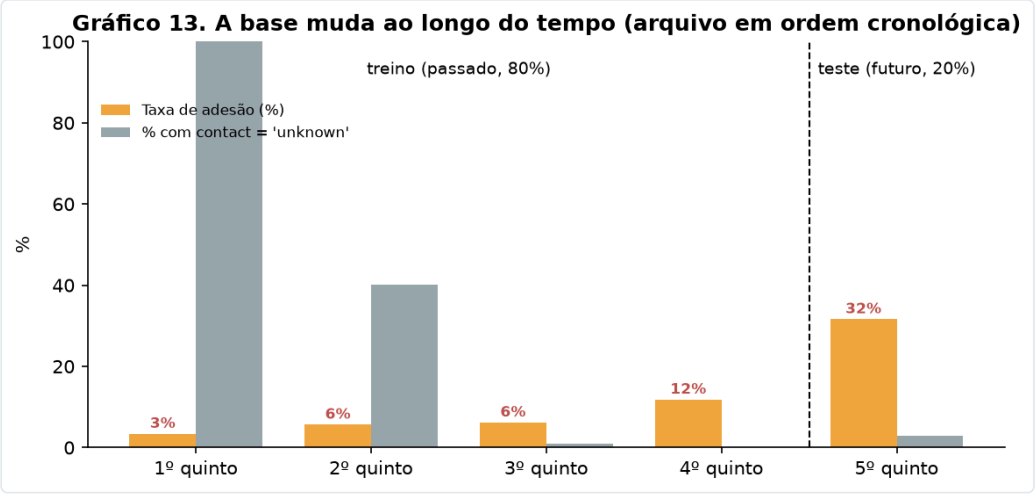


Figura 10. Taxa de adesão e participação de contact = unknown em cada quinto do arquivo (ordem cronológica).

5. Interface Gráfica

A interface segue a opção A do enunciado: uma **API FastAPI** (`app/app.py`) e uma página web (`app/index.html`, HTML + CSS + JavaScript). Ao iniciar, a API carrega com `joblib` o pré-processador (imputadores, `StandardScaler` e `OneHotEncoder`), o modelo XGBoost, o calibrador de Platt e o arquivo `metadados.json`; o modelo **nunca é retreinado**. A página busca em `/api/metadados` as categorias válidas e as faixas plausíveis, envia os 15 campos para `/api/prever` e mostra a **probabilidade calibrada**, a prioridade (alta ou baixa), quantas vezes ela está acima da média, a taxa real de adesão observada no teste para clientes daquela faixa, a posição em relação ao limiar e uma recomendação.

Como executar

```
cd "Trabalho final"
pip install -r requirements.txt
uvicorn app.app:app --reload
# abrir http://127.0.0.1:8000  (documentação da API em /docs)
```

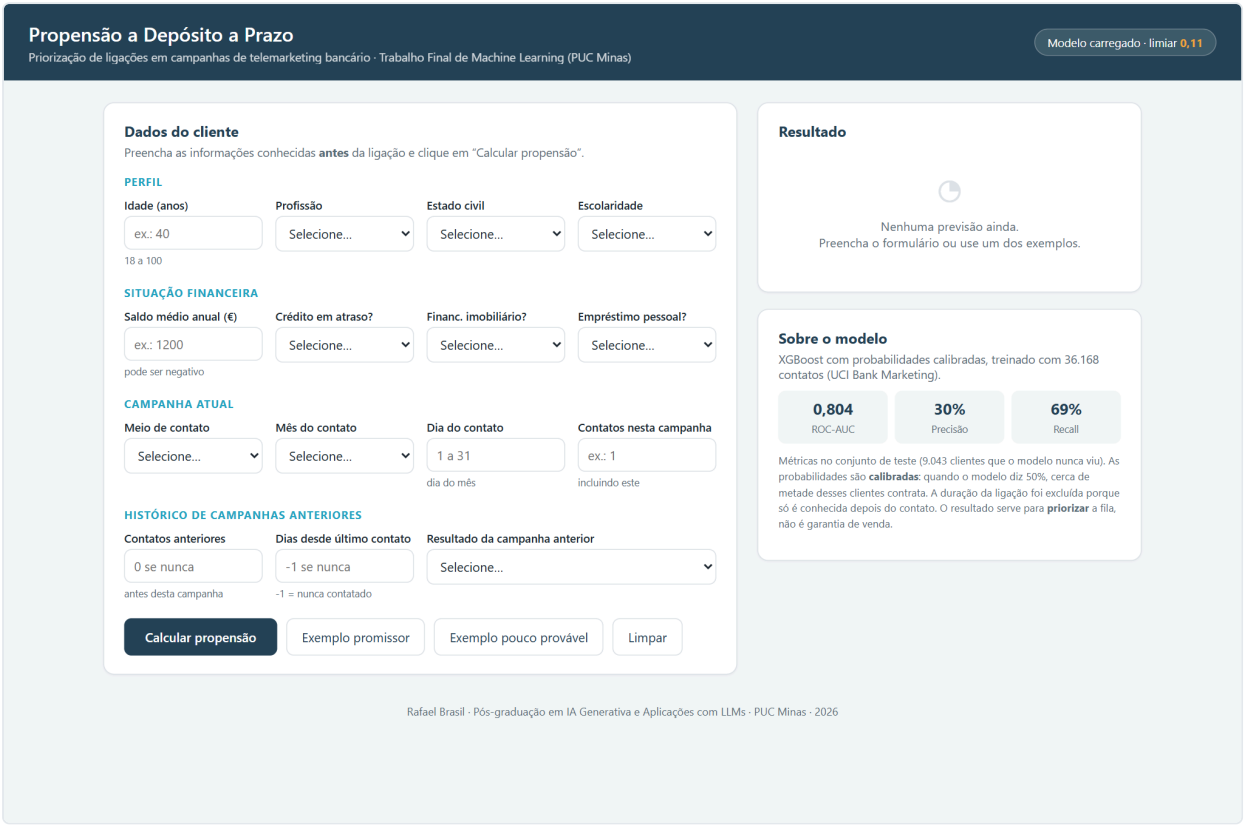


Figura 11. Tela principal: formulário com os 15 campos agrupados por tema, botões de exemplo e painel com as métricas do modelo.

Caso de sucesso: predição válida

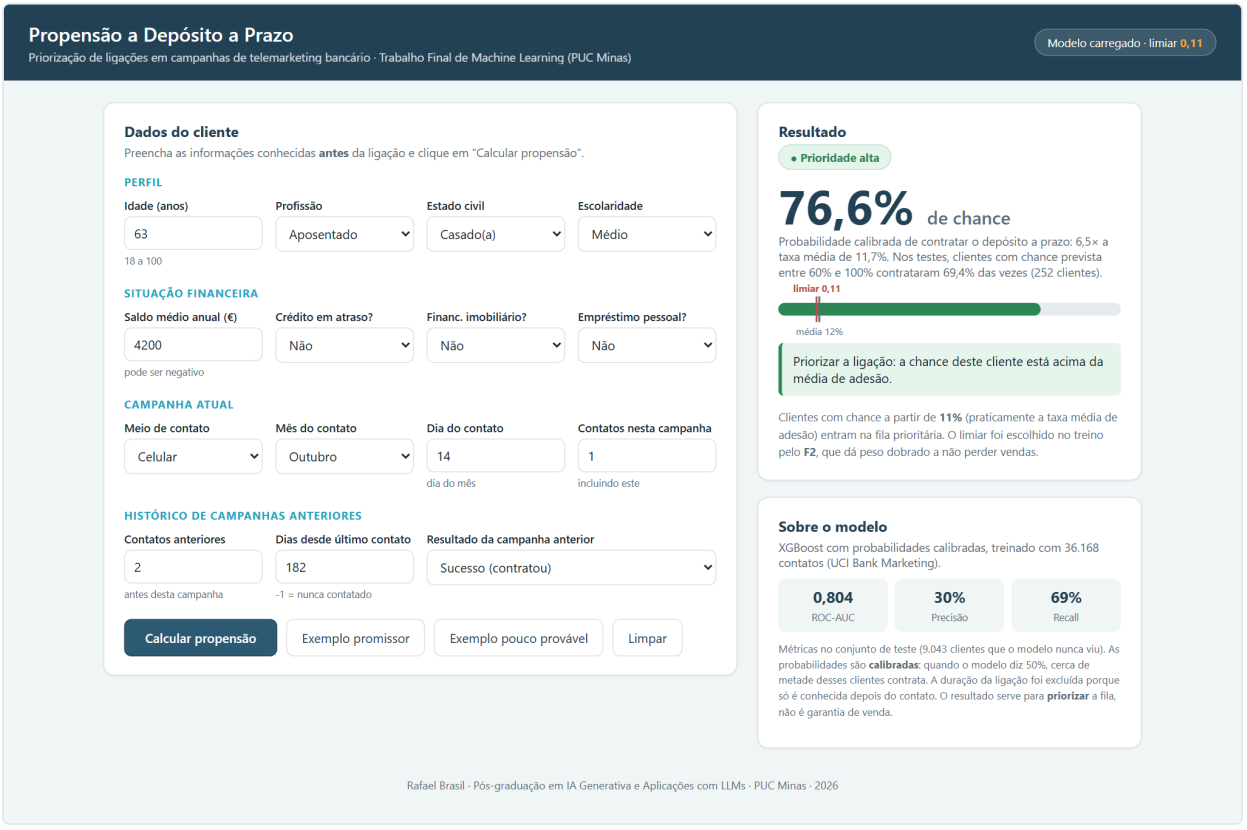


Figura 12. Cliente aposentado, contatado por celular em outubro, que aceitou na campanha anterior: chance muito acima da média, prioridade alta.

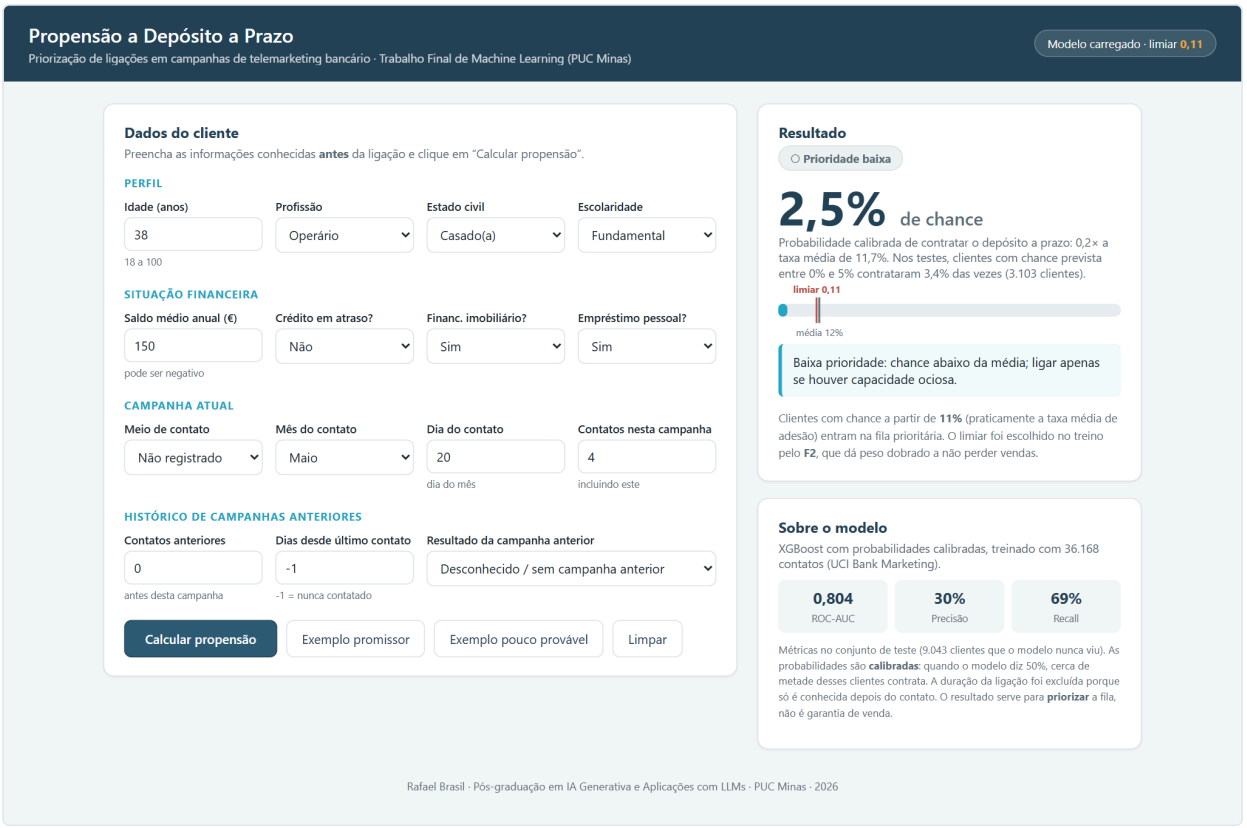


Figura 13. Operário com financiamento e empréstimo, contato não registrado em maio, nunca contatado antes: chance abaixo da média, prioridade baixa.

Caso negativo: entradas inválidas tratadas

A validação acontece em duas camadas. No navegador, campos vazios, texto no lugar de número e valores fora da faixa plausível são barrados antes do envio, com o campo destacado em vermelho e uma mensagem amigável. Na API, o **Pydantic** repete essas checagens (faixas, tipos, categorias válidas) e verifica a coerência do histórico do cliente; os erros voltam com HTTP 422 e mensagens em português, exibidas na página.

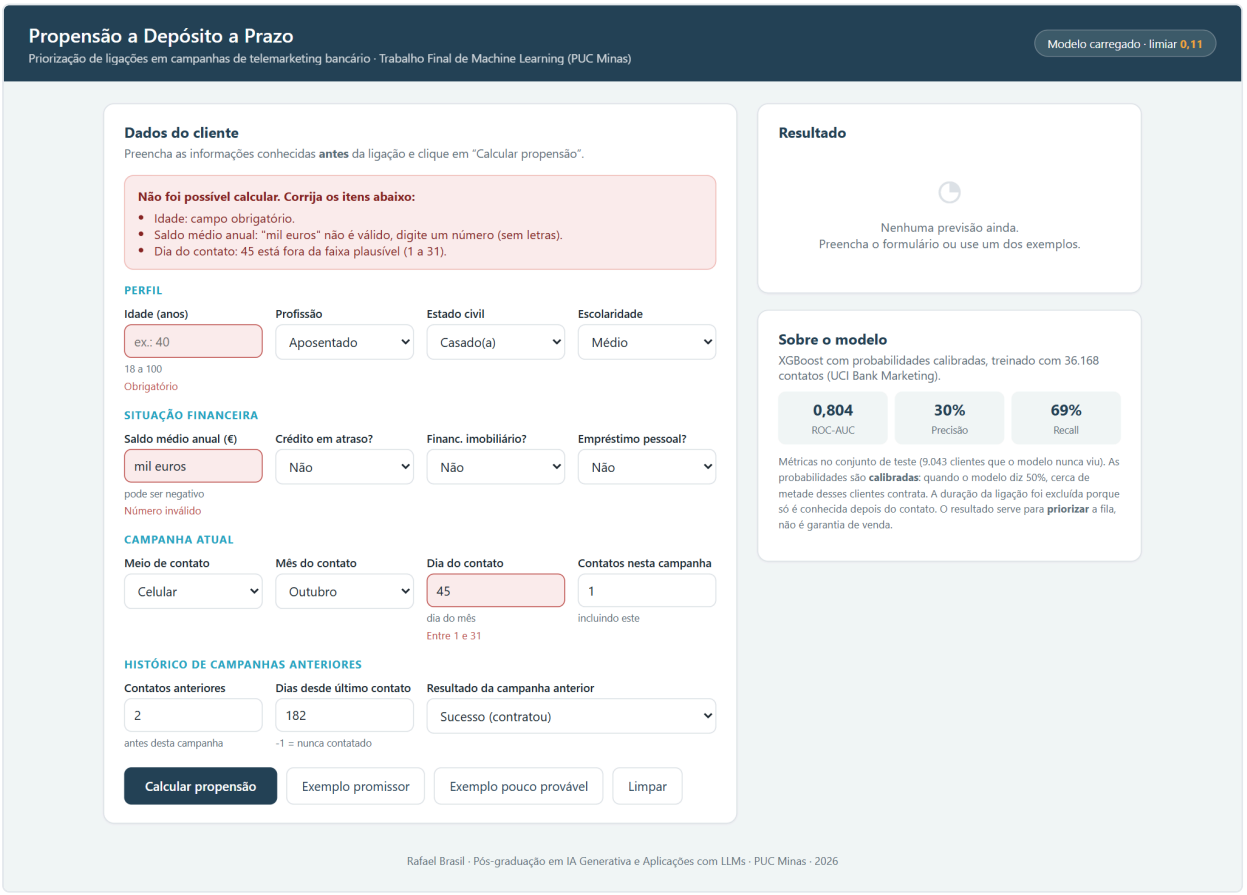


Figura 14. Erro tratado no navegador: idade vazia, "mil euros" no saldo e dia 45 do mês.

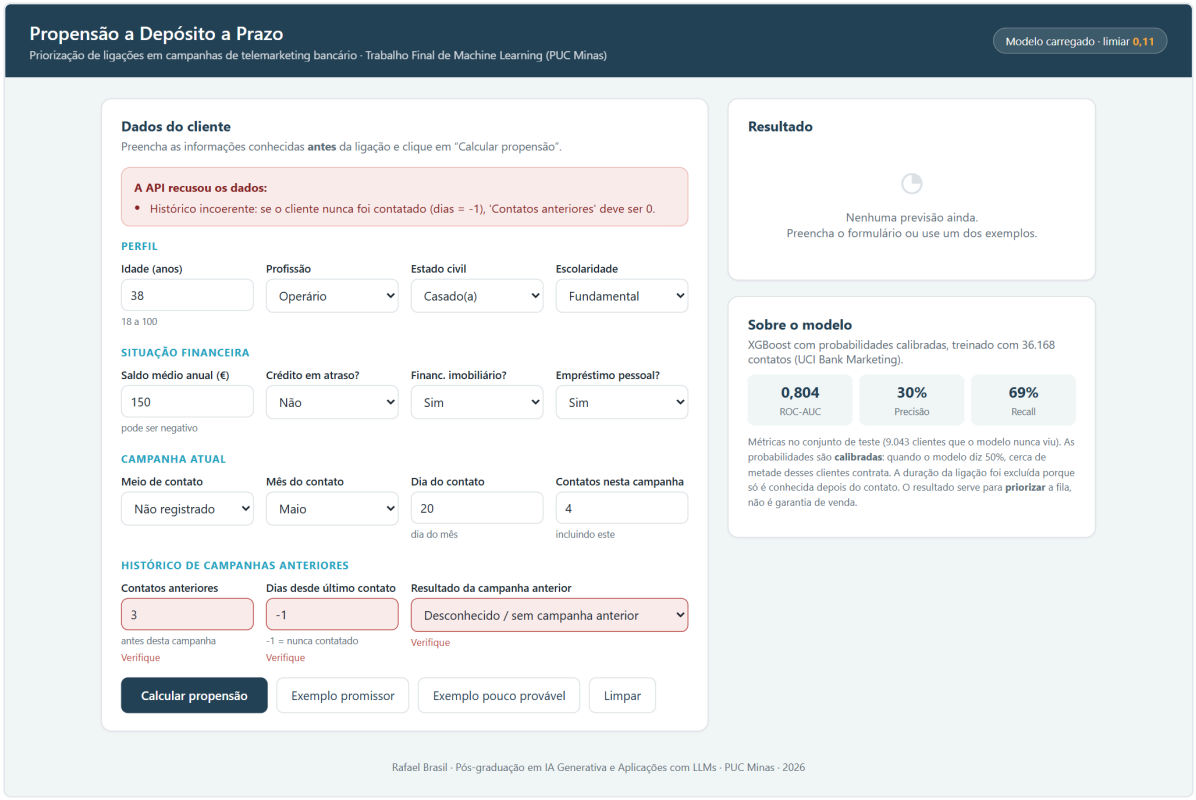


Figura 15. Erro tratado pela API: cliente marcado como nunca contatado (−1 dias) mas com 3 contatos anteriores.



Figura 16. Documentação automática da API (Swagger, em /docs).

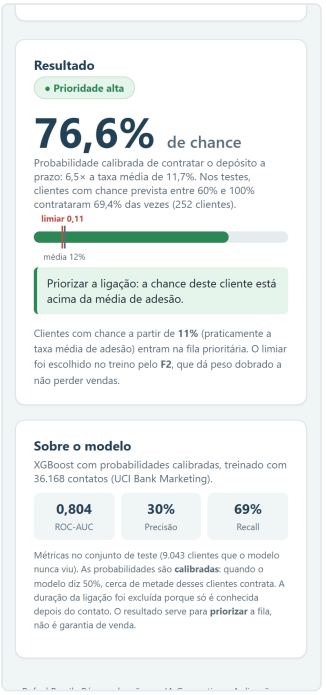


Figura 17. A página se adapta a telas de celular.

6. Conclusão

Resposta ao problema de negócio. Sim, é possível estimar antes da ligação a chance de um cliente contratar o depósito a prazo, com qualidade suficiente para priorizar a fila de telemarketing. O XGBoost final obteve ROC-AUC de 0,804 e PR-AUC de 0,464 no teste (contra 0,50 e 0,12 do acaso). Ligando só para os 20% de clientes com maior probabilidade, o banco alcança 63% dos interessados. Com a regra escolhida ("ligar para quem tem chance acima de 11%"), aciona 27% da base, encontra 69% dos clientes que contratariam, e a precisão das ligações é 2,6 vezes a taxa de adesão de uma campanha sem modelo.

Escolhas que mais pesaram. A remoção da coluna `duration`, a mais correlacionada com o alvo mas conhecida só depois da ligação; manter `unknown` como categoria; usar Pipeline para evitar vazamento; trocar a acurácia por ROC-AUC e PR-AUC (o modelo "sempre não" tem acurácia maior e é inútil); calibrar as probabilidades para que o número exibido na interface seja uma chance real; e escolher o limiar pelo F2, coerente com o custo maior de perder uma venda, sem usar o teste.

Limitações. Os dados são de um único banco português, de 2008 a 2010 (período de crise financeira), e precisam ser revalidados com dados atuais. No teste temporal (treinar no passado, prever o futuro) o ROC-AUC cai para 0,66: a taxa de adesão muda muito ao longo do tempo e variáveis como `month` e `contact` refletem a estratégia de cada período. A precisão de 30% significa que cerca de 7 em cada 10 ligações recomendadas ainda resultam em recusa, preço escolhido para perder menos vendas. O peso 2 do F2 é uma suposição, não um custo medido.

Melhorias futuras. Incluir os indicadores macroeconômicos da versão `bank-additional` (Euribor, confiança do consumidor), que ajudam a explicar a mudança da taxa ao longo do tempo; usar validação temporal na escolha do modelo; escolher o limiar pelo lucro esperado (custo da ligação × margem do depósito); mostrar na interface uma explicação individual da previsão com SHAP; e monitorar o desempenho e a calibração do modelo em produção.

Arquivos entregues e referências

Repositório no GitHub: https://github.com/rafaelmayerbrasil/trabalho-final-ml-bank-marketing (mesmo conteúdo do .zip entregue no portal).

Notebook `trabalho_final_bank_marketing.ipynb` (executado do início ao fim), pasta `modelo/` (`preprocessador.joblib`, `modelo.joblib`, `calibrador.joblib`, `metadados.json`), pasta `app/` (`app.py`, `index.html`), `dados/bank-full.csv`, `requirements.txt` e `README.md`.

MORO, S.; CORTEZ, P.; RITA, P. A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, v. 62, p. 22–31, 2014. · MORO, S.; RITA, P.; CORTEZ, P. Bank Marketing [Dataset]. UCI Machine Learning Repository, 2014. DOI 10.24432/C5K306. · PLATT, J. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, MIT Press, 1999. · Documentação do scikit-learn, XGBoost e FastAPI.

Uso de IA: o código, os experimentos e a redação foram produzidos com apoio do Claude (Anthropic), a pedido do aluno, que escolheu a base, a técnica e a interface. O registro completo está no fim do notebook.